

强化学习算法与实践课程

课程项目

学生版

编号	选题	算法主题（实现选做）
01	电量约束下的三维无人机航路规划	Q-learning；DQN / Double DQN 选做
02	专家示范预训练与强化学习微调的无人机避障	BC 预训练 + PPO 微调；DAgger 选做
03	无人机悬停与轨迹跟踪的强化学习控制	PPO 或 SAC 连续控制
04	学习动力学、模型预测控制与残差强化学习	动力学学习 + MPC + SAC 残差
05	风扰动与模型误差下的安全无人机控制	PPO / SAC 训练 + 安全过滤
06	多无人机协同航路与信用分配	独立 Q 学习 + VDN 或通信策略
07	LLM 任务解析与强化学习工具决策	固定 LLM + DQN 工具决策
08	扩散航路生成与 DPPO 强化学习微调	DDPM 预训练 + DPPO 微调
09	Flow Matching 与 FQL 无人机航路强化学习	流行为先验 + FQL 离线学习
10	生成式动作分块与残差强化学习飞行控制	生成动作块 + SAC 残差
11	语言条件生成策略与强化学习任务适配	任务条件预训练 + PPO 残差；语言扩展选做
12	生成式多无人机航路与 MAPPO 协同强化学习	联合生成先验 + MAPPO

任选一题，自选至少 2 篇实际使用强化学习的论文精读并比较；完成方案分析与汇报，实现选做。

课程汇报与评分要求

Presentation：文献阅读与方案分析

一、课程汇报与 PPT

选择一个课程项目，完成一次课程汇报（**Presentation**），并提交对应的 **PPT**（**PPTX** 及同版 **PDF**）。汇报主要包括文献阅读与方案分析：自行选择与本题相关的至少 2 篇论文精读，每篇均须实际使用强化学习，重点比较两篇论文；方案分析可选择本题应用方案或论文改进中的一个方向。

论文可自行选择，不限于推荐列表，优先选择近年正式发表的代表性工作。每篇精读论文均须实际使用强化学习方法，能讲清奖励或回报、策略或价值学习在论文中的作用；仅提及 RL，或自行设想为原方法增加 RL，不能满足选文要求。背景资料可辅助理解，不计入至少 2 篇精读论文。比较不同环境时须说明条件差异，不直接比较原文数值。

PPT 页数与结构自定，以讲清两篇论文及其比较为准。

二、汇报重点：两篇论文的精读与比较

1. 论文分别解决什么问题？说明研究目标、主要设定和核心思路，用自己的话讲清关键算法及强化学习在其中的作用。
2. 两篇论文有哪些实质差异？围绕问题设定、方法设计或实验结果展开比较，结合论文中的证据，说明各自的优势、局限与适用条件。可用对比表或示意图表达。
3. 阅读后有什么判断？可结合本题应用要求提出方案，也可分析所读论文方案的问题和可完善之处，说明自己的理由。

三、方案分析与引用说明

方案分析可任选以下一个方向：

1. 面向本题应用。结合题目的任务目标和约束，说明如何借鉴所读论文设计强化学习方案，以及需要作哪些调整。
2. 面向论文改进。说明精读的两篇论文各自在方法或应用上的问题，选择其中值得完善之处提出改进想法，并说明依据。

简要讲清“问题是什么、打算如何处理、为什么可行”即可，不要求完整推导或实现验证。各题的阅读问题和应用方案提示供参考，不要求逐项作答或另交报告。详细训练与实验设置供选做平台实现时使用。

引用图表、公式和结果时注明出处，末尾列出所读论文及 DOI 或正式链接；区分原论文结果与自己的实验结果。课程方案示意图不代表论文原图或实测结果。

基础成绩按文献阅读 85%、方案分析 15% 评定，平台实现为选做 Bonus。

评分细则

一、参考文献阅读：85 分（85%）

1. 问题与文献定位：**10 分**。文献信息及选文理由 4 分；研究问题、已有方法不足及论文贡献 6 分。自选至少 2 篇实际使用强化学习的论文，说明与所选项目的关系；优先形成近期进展与代表方法的比较。
2. 算法理解：**35 分**。建模、变量与假设 10 分；核心公式、优化目标和更新机制 15 分；训练与推理流程 10 分。应说明强化学习从何处获得反馈、更新哪些参数，区分预训练与强化学习阶段。
3. 实验解读：**20 分**。环境、数据、基线与实验设置 8 分；主要图表和结果解读 8 分；消融、失败情形或证据局限 4 分。避免仅凭曲线高低或单个指标判断优劣。
4. 对比与批判分析：**15 分**。两篇论文的实质性比较 8 分；有依据地分析适用条件与局限 7 分。不能只并列摘要或复述作者结论。
5. 表达与引用规范：**5 分**。引用及结果来源清楚 3 分；结构完整、图表可读、术语一致 2 分。重点是把两篇论文及其比较讲清楚。

二、方案分析：15 分（15%）

应用方案与论文改进任选一个方向，均按以下标准评分：

1. 问题分析：**6 分**。说明本题的应用需求与约束，或指出所读两篇论文方案存在的问题；问题具体，判断有依据。
2. 方案或改进思路：**5 分**。针对上述问题提出合理的应用方案或改进想法，讲清如何借鉴、调整论文中的方法及其与强化学习的关系。
3. 合理性说明：**4 分**。说明思路为什么可能有效，以及所需条件或可能的局限。无需完成实现或实验验证。

评分看重阅读理解、比较分析和判断依据，不以 PPT 篇幅长短计分。

三、平台实现：Bonus（选做，另计）

验收材料：可运行代码、环境与运行说明、训练配置与数据划分、训练前后参数、随机种子、日志与逐回合测试结果；明确个人实现和复用部分。

验收依据：（1）在课程平台完成真实强化学习训练，提供奖励驱动更新的证据；（2）完成本题基线对照、至少一项消融及失败分析，按题目要求报告独立测试结果；（3）平台能够按统一场景与预算复评。只有演示截图、预训练推理或自行填报成绩，不作为实现验收依据。

计分方式：Bonus 按实现完成度、实验质量与平台复评情况单独记录，具体加分额度由教师公布。未选做平台实现不扣基础分，不改变文献阅读 85% 与方案分析 15% 的权重。

01 电量约束下的三维无人机航路规划

一、任务与环境

在障碍、禁飞区和有限电量约束下学习到达目标的策略，比较已知地图搜索与奖励驱动学习的效率。

实验环境：课程 UAVGrid3D 离散网格，七种移动/悬停动作；表格方法固定地图和目标，留出起点测试。跨地图泛化仅作 DQN 扩展。

可选择精读 [R02] DQN 与 [R56] RAPID，比较价值学习、专家数据和奖励来源；经典方法解释基础，近年工作说明视觉导航扩展。




图 01：本题课程方案示意。箭头表示训练时的信息流；独立测试时冻结策略。

精读与比较提示（供参考）：

1. 写出 Q-learning 更新式，解释学习率、折扣和探索率；分别说明到达、碰撞与时间截断时是否继续自举。
2. 比较 DQN 与 RAPID 的观测、价值学习和奖励来源；说明专家数据与在线交互分别发挥什么作用。
3. 分析仅用位置作状态是否足够；举例说明同一位置在不同剩余电量下为何可能需要不同动作。

应用方案提示（也可选择论文改进）：

1. 用一张地图或流程图说明起终点、障碍和电量限制，列出位置与剩余电量等状态、离散动作及到达/失败奖励。
2. 说明采用 Q-learning 的理由，以 A* 为对照，比较成功率与路径长度；简述现有网格环境能否支持方案。

二、训练设置（Bonus）

算法：Q-learning 必做；DQN 或 Double DQN 作为改进路线。

训练参数：Q 表；DQN 扩展训练在线 Q 网络，目标网络由复制或滑动平均更新。

状态与动作：位置、目标、地图/禁飞区与剩余电量。环境支持的离散位移或悬停指令。

奖励与终止：到达奖励 – 碰撞/禁飞惩罚 – 飞行步数与电量消耗；写出权重并固定。到达、耗尽电量或任务失败终止；步数上限作为截断单独记录。

三、平台实现（Bonus）

1. 完成 Q-learning 训练，保存 Q 表；选做 DQN 或 Double DQN 时，同时提交网络参数。
2. 说明电量如何进入状态、奖励和终止条件，检查所学策略能否在剩余电量内到达目标。
3. 完成下列对照实验，并从奖励权重、探索策略或状态设计中任选一项消融。
4. 保存训练前后 Q 表或网络、探索率与回报曲线；可选择“状态不含电量”作为上述消融，检查电量耗尽。
5. 提交至少一个成功与一个失败回合的路径图，标注逐步剩余电量；越界、碰撞或非法动作不得从失败统计中删除。

四、对照实验（Bonus）

A*、随机、初始 Q 策略、训练后 Q-learning 及所选改进；共享测试起点，学习方法固定训练预算，A* 另计搜索开销。

报告指标：成功率、禁飞或越界尝试次数、路径步数、离散电量消耗；另附训练回报、损失与计算预算。

选做实现：每个学习方法至少 3 个独立训练种子，每个模型至少 30 个测试回合；三组复评不等于三次训练。固定数据划分与预算，测试集不调参；传统算法另计搜索成本。失败计入完成率，误差/长度注明失败处理。

五、代码起点（Bonus）

环境包提供网格环境、状态转移和 A* 传统对照；Q-learning 及 DQN 训练由学生实现。默认示例只检查环境，policy.py 留待实现；运行通过不代表作业完成。

下载本题实践包

课程汇报 (Presentation)

汇报内容与 PPT：完成一次课程汇报，并提交对应 PPT (PPTX 及同版 PDF)。汇报以文献阅读与方案分析为主：自行选择与本题相关的至少 2 篇论文精读，每篇均须实际使用强化学习，重点比较两篇论文；方案分析可结合本题应用要求提出方案，或说明所读论文方案的问题与可完善之处，任选一个方向。PPT 页数与结构自定。汇报要求见第2页，评分见第3页。

可选提交：平台实现 (Bonus)。可在课程汇报之外提交平台实现，包括可运行代码、环境配置、训练参数与日志、随机种子和测试结果，并注明个人实现与复用部分。实现结果由平台统一复评，作为额外加分依据。

汇报评分：文献阅读 85%，方案分析 15%；平台实现为可选 Bonus，未提交不影响汇报成绩。

参考文献 (推荐清单，可自行另选)

强化学习论文 (可供精读比较)

[R02] Human-level control through deep reinforcement learning

Nature, 2015, 正式发表。

阅读重点：奖励驱动的离散价值学习。理解 Q 网络、经验回放、目标网络与 TD 更新的作用；讨论本题状态、合法动作和奖励的定义。

[R56] RAPID: Robust and Agile Planner Using Inverse Reinforcement Learning for Vision-Based Drone Navigation

RSS, 2025, 正式发表。

阅读重点：逆强化学习结合专家数据与在线交互，学习视觉导航航点。比较状态表示、专家信息与奖励建模；迁移到本题时需补充电量状态和约束。

[R01] Q-learning

Machine Learning, 1992, 正式发表。

阅读重点：MDP 与价值更新。写出状态、动作、转移、终止条件与 Bellman 更新；分析探索覆盖和稀疏奖励。

[R30] Decentralized Learning-Driven AoI Optimization in UAV-Assisted Wireless Powered Edge Networks

IEEE Transactions on Mobile Computing, 2026, 正式发表。

阅读重点：AoI 与边缘任务调度。阅读 AoI 状态演化与去中心化学习；新增充电、关联和调度变量后再评价 AoI。

[R06] Deep Reinforcement Learning Based Resource Allocation and Trajectory Planning in Integrated Sensing and Communications UAV Network

IEEE Transactions on Wireless Communications, 2023, 正式发表。

阅读重点：航路与通信资源联合决策。读状态动作中的轨迹及资源变量；讨论能量与任务收益的联合代价，作为新增通信场景方向。

背景参考 (不计入两篇精读论文)

[R03] A Formal Basis for the Heuristic Determination of Minimum Cost Paths

IEEE Transactions on Systems Science and Cybernetics, 1968, 正式发表。

阅读重点：启发式搜索基线。读启发式可采纳性与代价函数；理解 A* 搜索过程，讨论电量是否必须进入搜索状态。

02 专家示范预训练与强化学习微调的无人机避障

一、任务与环境

研究专家示范初始化是否能够改善强化学习的样本效率，以及策略能否在示范未覆盖的场景中纠错。

实验环境：先使用 UAV01 网格；进阶使用视觉仿真，不混用两个赛道。

可选择精读 [R56] RAPID 与 [R57] Policy Decorator，比较专家数据的使用方式及后续 RL 更新；BC、DAgger 与 PPO 作为本题实现基础。




图 02：本题课程方案示意。箭头表示训练时的信息流；独立测试时冻结策略。

精读与比较提示（供参考）：

1. 解释 BC 中的分布偏移；说明 DAgger 由谁执行、在哪些状态查询专家，以及数据集为何需要聚合。
2. 写出 PPO 的概率比和裁剪目标，解释优势估计；指出从 BC 切换到 PPO 后，监督标签被什么反馈取代。
3. 从论文中分析示范质量、专家查询量与环境交互量的关系；说明为何不能只比较最终成功率。

应用方案提示（也可选择论文改进）：

1. 画“专家示范—BC 预训练—PPO 微调”流程，说明各阶段学什么，以及 PPO 使用什么任务奖励。
2. 以仅 BC 为对照，比较成功率与达到相同成功率所需交互量；简述专家示范如何获取。

二、训练设置（Bonus）

算法：BC 预训练 + PPO 在线微调；DAgger 数据聚合选做。

训练参数：BC 离散策略 π_θ ；强化学习阶段继续更新 π_θ 和价值网络 $V\phi$ 。

状态与动作：当前位置、目标、剩余电量及地图/局部障碍观测；不输入专家动作。离散避障动作的 Categorical 策略。

奖励与终止：到达奖励 - 碰撞/禁飞惩罚 - 路径与能耗代价；PPO 阶段不以专家交叉熵替代奖励。到达、碰撞/电量耗尽等环境终止；回合预算截断。

三、平台实现（Bonus）

1. 采集专家示范，完成 BC 预训练（DAgger 选做），再用 PPO 继续训练策略和价值网络。
2. 记录示范数据量与专家查询次数，绘制示范初始化和随机初始化 PPO 的学习曲线。
3. 在未参与训练的地图上比较成功率和交互步数，分析示范未覆盖的状态下策略如何失效或恢复。
4. 提交示范数据统计、预训练参数及微调参数；训练日志须能区分 BC 损失与 PPO 回报，测试地图不得参与专家采集。
5. 在相同交互预算下报告预训练前、预训练后和 PPO 微调后的结果；提供至少一个专家之外状态的恢复或失败轨迹。

四、对照实验（Bonus）

专家、BC、随机初始化 PPO、BC 初始化 PPO；DAgger 仅在选做时对照。统一在线步数，专家数据成本另报。报告指标：成功率、禁飞尝试率、路径比、专家查询次数；另附训练回报、损失与计算预算。

选做实现：每个学习方法至少 3 个独立训练种子，每个模型至少 30 个测试回合；三组复评不等于三次训练。固定数据划分与预算，测试集不调参；传统算法另计搜索成本。失败计入完成率，误差/长度注明失败处理。

五、代码起点（Bonus）

环境包提供网格避障环境和 A* 数据工具；BC 预训练、PPO 微调及选做 DAgger 由学生实现。默认示例只检查环境，policy.py 留待实现；运行通过不代表作业完成。

下载本题实践包

课程汇报 (Presentation)

汇报内容与 PPT: 完成一次课程汇报, 并提交对应 PPT (PPTX 及同版 PDF)。汇报以文献阅读与方案分析为主: 自行选择与本题相关的至少 2 篇论文精读, 每篇均须实际使用强化学习, 重点比较两篇论文; 方案分析可结合本题应用要求提出方案, 或说明所读论文方案的问题与可完善之处, 任选一个方向。PPT 页数与结构自定。汇报要求见第2页, 评分见第3页。

可选提交: 平台实现 (Bonus)。可在课程汇报之外提交平台实现, 包括可运行代码、环境配置、训练参数与日志、随机种子和测试结果, 并注明个人实现与复用部分。实现结果由平台统一复评, 作为额外加分依据。

汇报评分: 文献阅读 85%, 方案分析 15%; 平台实现为可选 Bonus, 未提交不影响汇报成绩。

参考文献 (推荐清单, 可自行另选)

强化学习论文 (可供精读比较)

[R56] RAPID: Robust and Agile Planner Using Inverse Reinforcement Learning for Vision-Based Drone Navigation
RSS, 2025, 正式发表。

阅读重点: 逆强化学习结合专家数据与在线交互, 学习视觉导航航点。比较状态表示、专家信息与奖励建模; 迁移到本题时需补充电量状态和约束。

[R57] Policy Decorator: Model-Agnostic Online Refinement for Large Policy Model
ICLR, 2025, 正式发表。

阅读重点: 冻结模仿策略, 以 SAC 训练残差策略并限制早期探索。区分示范预训练与在线奖励更新; 原文为机器人操作, 飞行应用需调整动作和安全边界。

[R08] Proximal Policy Optimization Algorithms
arXiv, 2017, 算法原始预印本。

阅读重点: 裁剪策略梯度与优势估计。理解 PPO 采样、旧策略概率、GAE 和 actor/critic 更新; 解读样本效率、回报与留出场景表现。

背景参考 (不计入两篇精读论文)

[R07] A Reduction of Imitation Learning and Structured Prediction to No-Regret Online Learning
AISTATS, 2011, 正式发表。

阅读重点: 闭环分布偏移与数据聚合。重点读数据聚合算法和专家查询; 理解多轮数据聚合如何缓解分布偏移, 以及专家查询的代价。

[R09] Learning High-Speed Flight in the Wild
Science Robotics, 2021, 正式发表。

阅读重点: 无人机特权专家与模仿学习。理解训练专家和部署策略所见信息的区别; 讨论信息限制和闭环评测如何迁移到栅格环境。

[R12] Diffusion Policy: Visuomotor Policy Learning via Action Diffusion
RSS, 2023, 正式发表。

阅读重点: 多模态动作模仿。阅读条件动作去噪; 作为生成式模仿扩展, 比较不同可行绕障路线。

03 无人机悬停与轨迹跟踪的强化学习控制

一、任务与环境

研究强化学习悬停控制，轨迹跟踪作为扩展；比较学习控制器和 PID 在名义与扰动条件下的表现。

实验环境：平台提供二维平面四旋翼教学动力学；动作为总推力与俯仰力矩。进阶迁移到 PyBullet。

可选择精读 [R15] 快速飞行训练与 [R58] 视觉飞行，也可比较 [R59] Actor-Critic MPC；重点分析观测、控制接口与样本效率。




图 03：本题课程方案示意。箭头表示训练时的信息流；独立测试时冻结策略。

精读与比较提示（供参考）：

1. 比较 PPO 与 SAC 的数据复用方式、策略输出和更新目标；选择一种作为本题主算法，并说明选择依据。
2. 说明论文中的观测、动作和控制频率；把它们映射到平面模型，避免将三维电机转速直接作为本题动作。
3. 解释跟踪误差、姿态、控制变化量如何共同评价控制器；分析奖励改善但姿态峰值变大的可能原因。

应用方案提示（也可选择论文改进）：

1. 画状态观测、PPO 或 SAC、动力学环境的闭环图，说明推力/力矩动作及跟踪奖励。
2. 以 PID 为对照，比较轨迹跟踪误差与失稳率；简述选择悬停还是轨迹跟踪作为入门验证。

二、训练设置（Bonus）

算法：PPO 或 SAC 至少一种；选做实现的入门任务为悬停控制，轨迹跟踪选做，按任务分别评测。

训练参数：PPO 策略和价值网络；或 SAC 随机策略、双 Q 与目标网络。

状态与动作：位置、速度、姿态/角速度、参考轨迹误差及必要历史；以所选仿真实际支持的状态为准。课程仿真的连续控制量，统一限幅和控制频率。

奖励与终止：负跟踪误差、控制能耗与失稳惩罚，加入任务完成项；报告各权重。失稳/越界等失败终止；固定控制时长作为截断。

三、平台实现（Bonus）

1. 选择 PPO 或 SAC，从初始化开始训练悬停策略；轨迹跟踪为扩展，并单独报告任务。
2. 统一动作限幅、控制频率和测试条件，比较 PID、未训练策略和训练后策略。悬停使用固定目标点；跟踪扩展使用统一参考轨迹。
3. 在名义条件与未参与训练的质量、风扰动条件下测试；至少改变一项奖励设置或观测输入，分析影响。
4. 记录控制频率、训练步数及动作饱和比例；同时提交轨迹、姿态、推力和力矩曲线，不能只提交回报曲线。
5. 按所选悬停或跟踪任务完成上述对照；可选择去除控制平滑惩罚作为消融，并分析振荡。

四、对照实验（Bonus）

PID、未训练策略、训练后策略；名义与留出质量/风扰动。

报告指标：位置 RMSE、姿态峰值、约束违反率、推力变化量；另附训练回报、损失与计算预算。

选做实现：每个学习方法至少 3 个独立训练种子，每个模型至少 30 个测试回合；三组复评不等于三次训练。固定数据划分与预算，测试集不调参；传统算法另计搜索成本。失败计入完成率，误差/长度注明失败处理。

五、代码起点（Bonus）

环境包提供二维动力学、推力/力矩接口和 PID 传统对照；PPO 或 SAC 训练由学生实现。默认示例只检查环境，policy.py 留待实现；运行通过不代表作业完成。

下载本题实践包

课程汇报 (Presentation)

汇报内容与 PPT：完成一次课程汇报，并提交对应 PPT (PPTX 及同版 PDF)。汇报以文献阅读与方案分析为主：自行选择与本题相关的至少 2 篇论文精读，每篇均须实际使用强化学习，重点比较两篇论文；方案分析可结合本题应用要求提出方案，或说明所读论文方案的问题与可完善之处，任选一个方向。PPT 页数与结构自定。汇报要求见第2页，评分见第3页。

可选提交：平台实现 (Bonus)。可在课程汇报之外提交平台实现，包括可运行代码、环境配置、训练参数与日志、随机种子和测试结果，并注明个人实现与复用部分。实现结果由平台统一复评，作为额外加分依据。

汇报评分：文献阅读 85%，方案分析 15%；平台实现为可选 Bonus，未提交不影响汇报成绩。

参考文献 (推荐清单，可自行另选)

强化学习论文 (可供精读比较)

[R15] Learning to Fly in Seconds

IEEE Robotics and Automation Letters, 2024, 正式发表。

阅读重点：四旋翼 RL 训练与 Sim2Real。读强化学习控制器、训练随机化和快速动力学仿真；借鉴训练组织方式，避免照搬训练时间结论。

[R58] Demonstrating Agile Flight from Pixels without State Estimation

RSS, 2024, 正式发表。

阅读重点：视觉飞行中的强化学习与非对称训练。比较训练特权信息、部署观测及控制输出；分析视觉误差和仿真到实机的差异。

[R59] Actor-Critic Model Predictive Control

ICRA, 2024, 正式发表。

阅读重点：将可微 MPC 嵌入策略，以 Actor-Critic 学习长期回报。比较优化器、价值函数及梯度路径，解释 MPC 与 RL 如何共同改进飞行控制。

[R08] Proximal Policy Optimization Algorithms

arXiv, 2017, 算法原始预印本。

阅读重点：裁剪策略梯度与优势估计。理解 PPO 采样、旧策略概率、GAE 和 actor/critic 更新；解读样本效率、回报与留出场景表现。

[R11] Soft Actor-Critic: Off-Policy Maximum Entropy Deep Reinforcement Learning with a Stochastic Actor

ICML, 2018, 正式发表。

阅读重点：最大熵强化学习与残差控制。理解双 Q、目标网络、回放与随机策略更新；分析残差控制如何通过组合动作获得环境回报。

背景参考 (不计入两篇精读论文)

[R16] Safe-Control-Gym: A Unified Benchmark Suite for Safe Learning-Based Control and Reinforcement Learning in Robotics

IEEE Robotics and Automation Letters, 2022, 正式发表。

阅读重点：控制与 RL 统一评测。借鉴扰动、约束、样本效率及轨迹误差的报告方式；完整 PyBullet 环境为独立扩展。

04 学习动力学、模型预测控制与残差强化学习

一、任务与环境

学习近似动力学用于 MPC，再学习残差策略补偿模型误差，区分模型拟合与奖励驱动控制优化。

实验环境：UAV03 同一二维动力学及推力与力矩动作；使用真实模型的规划器作为性能参考。

建议从 [R59] Actor-Critic MPC、[R60] TD-MPC2 与 [R61] DreamerV3 中精读 2 篇，比较模型、规划和策略更新的位置；本题“MPC 加 SAC 残差”为课程组合方案，并非三篇原文的直接复现。




图 04：本题课程方案示意。箭头表示训练时的信息流；独立测试时冻结策略。

精读与比较提示（供参考）：

1. 说明动力学模型预测下一状态还是状态增量；分析一步预测误差与多步闭环控制误差为什么不等价。
2. 解释 MPC 的预测时域、约束和滚动执行；区分训练模型、规划优化器及真实仿真环境的作用。
3. 写出组合动作与残差策略的学习目标；说明价值函数需要如何反映 MPC 加残差实际产生的环境回报。

应用方案提示（也可选择论文改进）：

1. 画“学习动力学—MPC—SAC 残差”框图，说明基础动作与残差如何组合，以及残差从何种奖励学习。
2. 以不加残差的学习模型 MPC 为对照，比较跟踪误差与控制变化量；指出模型误差这一主要风险。

二、训练设置（Bonus）

算法：监督动力学学习 + MPC + SAC 残差强化学习。

训练参数：状态差分动力学模型；SAC 残差策略、双 Q 与目标网络。

状态与动作：当前物理状态、参考误差、MPC 基础动作与上一时刻已观测的预测误差；不得使用当前动作执行后才可得到的信息。有界连续残差 δu ，执行 $u = \text{clip}(u_{\text{MPC}} + \delta u)$ 。

奖励与终止：负跟踪误差、能耗、残差幅值与约束违反代价；环境反馈形成转移数据。安全边界失败终止；控制时长预算截断。

三、平台实现（Bonus）

1. 用采集到的状态转移拟合动力学，接入 MPC，报告一步预测误差与闭环控制效果。
2. 固定动力学模型和 MPC 设置，训练 SAC 残差策略；说明残差范围及与基础动作的叠加方式。
3. 比较有无残差及训练前后的结果，分别统计环境交互次数和 MPC 模型调用次数。
4. 提交独立验证集的一步和多步预测误差，并保存残差训练前后的模型；不得只用训练集拟合误差证明有效。
5. 残差训练须在实际组合控制回路中进行；报告 MPC 动作、残差、最终限幅动作及求解时延。

四、对照实验（Bonus）

PID、学习模型 MPC、MPC+ 未训练残差、MPC+SAC；相同真实交互预算，规划模型调用另报。

报告指标：位置 RMSE、模型多步误差、真实交互步数、单次规划时延；另附训练回报、损失与计算预算。

选做实现：每个学习方法至少 3 个独立训练种子，每个模型至少 30 个测试回合；三组复评不等于三次训练。固定数据划分与预算，测试集不调参；传统算法另计搜索成本。失败计入完成率，误差/长度注明失败处理。

五、代码起点（Bonus）

环境包提供二维动力学和控制接口；动力学学习、MPC 及 SAC 残差由学生实现。默认示例只检查环境，policy.py 留待实现；运行通过不代表作业完成。

下载本题实践包

课程汇报 (Presentation)

汇报内容与 PPT: 完成一次课程汇报, 并提交对应 PPT (PPTX 及同版 PDF)。汇报以文献阅读与方案分析为主: 自行选择与本题相关的至少 2 篇论文精读, 每篇均须实际使用强化学习, 重点比较两篇论文; 方案分析可结合本题应用要求提出方案, 或说明所读论文方案的问题与可完善之处, 任选一个方向。PPT 页数与结构自定。汇报要求见第2页, 评分见第3页。

可选提交: 平台实现 (Bonus)。可在课程汇报之外提交平台实现, 包括可运行代码、环境配置、训练参数与日志、随机种子和测试结果, 并注明个人实现与复用部分。实现结果由平台统一复评, 作为额外加分依据。

汇报评分: 文献阅读 85%, 方案分析 15%; 平台实现为可选 Bonus, 未提交不影响汇报成绩。

参考文献 (推荐清单, 可自行另选)

强化学习论文 (可供精读比较)

[R59] Actor-Critic Model Predictive Control

ICRA, 2024, 正式发表。

阅读重点: 将可微 MPC 嵌入策略, 以 Actor-Critic 学习长期回报。比较优化器、价值函数及梯度路径, 解释 MPC 与 RL 如何共同改进飞行控制。

[R60] TD-MPC2: Scalable, Robust World Models for Continuous Control

ICLR, 2024, 正式发表。

阅读重点: 潜在动力学、奖励和价值学习与滚动规划。比较模型预测误差和闭环回报; 讨论迁移到飞行控制所需的数据与约束。

[R61] Mastering diverse control tasks through world models

Nature, 2025, 正式发表 (DreamerV3)。

阅读重点: 世界模型内的想象轨迹与 Actor-Critic 训练。与 MPC 比较规划和策略学习的位置; 区分模型监督损失与奖励驱动的策略更新。

[R18] Neural Network Dynamics for Model-Based Deep Reinforcement Learning with Model-Free Fine-Tuning

ICRA, 2018, 正式发表。

阅读重点: 神经动力学与随机射击 MPC。重点读状态差分预测、候选动作序列与滚动优化; 理解确定性模型与随机射击规划的配合方式。

[R11] Soft Actor-Critic: Off-Policy Maximum Entropy Deep Reinforcement Learning with a Stochastic Actor

ICML, 2018, 正式发表。

阅读重点: 最大熵强化学习与残差控制。理解双 Q、目标网络、回放与随机策略更新; 分析残差控制如何通过组合动作获得环境回报。

背景参考 (不计入两篇精读论文)

[R19] Data-Driven MPC for Quadrotors

IEEE Robotics and Automation Letters, 2021, 正式发表。

阅读重点: 无人机学习残差 MPC。阅读名义动力学、GP 气动力残差与 MPC 耦合; 借鉴残差建模, 不要求完全复现原实机实验。

05 风扰动与模型误差下的安全无人机控制

一、任务与环境

在风扰动和模型误差下训练控制策略，研究约束过滤对安全性、跟踪效果及训练过程的影响。

实验环境：UAV03 教学模型或 safe control gym；必须按环境分榜。

可比较 [R62] GCPO 与 [R08] PPO 的约束处理和策略更新；安全过滤、CBF 与流采样校正论文作为背景，也可自选其他安全强化学习论文。




图 05：本题课程方案示意。箭头表示训练时的信息流；独立测试时冻结策略。

精读与比较提示（供参考）：

1. 区分奖励惩罚、动作限幅和安全过滤；说明哪一种可以在什么假设下提供安全保证，哪些只能给出经验结果。
2. 解释 CBF 或预测安全过滤的约束及优化目标；说明动力学不确定、观测噪声和求解不可行对结论的影响。
3. 分析过滤器怎样改变训练数据分布；说明价值学习使用哪个动作，以及策略梯度计算应对应哪条采样策略。

应用方案提示（也可选择论文改进）：

1. 画“策略—安全过滤—环境”框图，选定一项安全约束，说明任务奖励与安全层各自的作用。
2. 以无过滤器的策略为对照，比较约束违反率与跟踪误差；简述过滤器依赖的模型或状态信息。

二、训练设置（Bonus）

算法：PPO 或 SAC 策略训练 + 安全过滤；必须提交本题训练过程。

训练参数：PPO 策略和价值函数（或 SAC actor/critic）；安全过滤器按约束求解。

状态与动作：可观测飞行状态、跟踪误差和安全余量；真实扰动未知量不直接输入部署策略。策略输出控制提案；CBF-QP 或预测安全过滤后执行。

奖励与终止：任务回报 - 跟踪误差 - 控制代价 - 安全介入/违规代价；安全指标独立报告。越过实际安全边界/失稳终止；时长上限截断。

三、平台实现（Bonus）

1. 在本题扰动分布下训练 PPO 或 SAC。可从 UAV03 权重开始，但仍须完成本题训练。
2. 实现 CBF-QP 或预测安全过滤器，分别记录策略提案、执行动作及过滤器介入次数。
3. 比较同一策略有无过滤器、训练时有无扰动的结果；测试条件不能用于选择模型。
4. 独立记录过滤器修正幅度、求解失败、真实约束违反和任务失败；将过滤器视为环境的一部分：回放存策略提案及实际回报，另记执行动作；PPO 概率对应原始采样动作，SAC 的 Q 与策略更新同用提案动作。
5. 报告名义与超出训练范围的扰动结果，分析至少一个失败案例；有限测试无违规不能表述为无条件安全保证。

四、对照实验（Bonus）

同一训练策略有/无过滤；无扰动训练与扰动训练；测试条件不用于选择模型。

报告指标：约束违反率、位置 RMSE、过滤介入率、控制计算时延；另附训练回报、损失与计算预算。

选做实现：每个学习方法至少 3 个独立训练种子，每个模型至少 30 个测试回合；三组复评不等于三次训练。固定数据划分与预算，测试集不调参；传统算法另计搜索成本。失败计入完成率，误差/长度注明失败处理。

五、代码起点 (Bonus)

环境包提供二维动力学与扰动参数；安全过滤和 PPO 或 SAC 训练由学生实现。默认示例只检查环境，policy.py 留待实现；运行通过不代表作业完成。

下载本题实践包

课程汇报 (Presentation)

汇报内容与 PPT：完成一次课程汇报，并提交对应 PPT (PPTX 及同版 PDF)。汇报以文献阅读与方案分析为主：自行选择与本题相关的至少 2 篇论文精读，每篇均须实际使用强化学习，重点比较两篇论文；方案分析可结合本题应用要求提出方案，或说明所读论文方案的问题与可完善之处，任选一个方向。PPT 页数与结构自定。汇报要求见第2页，评分见第3页。

可选提交：平台实现 (Bonus)。可在课程汇报之外提交平台实现，包括可运行代码、环境配置、训练参数与日志、随机种子和测试结果，并注明个人实现与复用部分。实现结果由平台统一复评，作为额外加分依据。

汇报评分：文献阅读 85%，方案分析 15%；平台实现为可选 Bonus，未提交不影响汇报成绩。

参考文献 (推荐清单，可自行另选)

强化学习论文 (可供精读比较)

[R62] Game-Theoretic Constrained Policy Optimization for Safe Reinforcement Learning

IEEE Transactions on Neural Networks and Learning Systems, 2025, 正式发表。

阅读重点：GCPO 将安全约束纳入策略优化，并在四旋翼跟踪等任务验证。比较训练约束与执行时安全过滤，分析可行性、性能和约束违例。

[R08] Proximal Policy Optimization Algorithms

arXiv, 2017, 算法原始预印本。

阅读重点：裁剪策略梯度与优势估计。理解 PPO 采样、旧策略概率、GAE 和 actor/critic 更新；解读样本效率、回报与留出场景表现。

背景参考 (不计入两篇精读论文)

[R24] A predictive safety filter for learning-based control of constrained nonlinear dynamical systems

Automatica, 2021, 正式发表。

阅读重点：预测安全过滤。读预测可行性、终端安全集合与回退条件；据此设计可复现的安全过滤器。

[R23] Control Barrier Function Based Quadratic Programs for Safety Critical Systems

IEEE Transactions on Automatic Control, 2017 卷期, 2016 在线发表。

阅读重点：控制障碍函数与安全集合。读前向不变性条件、CBF 不等式与 QP 约束；说明离散采样和模型误差对保证的影响。

[R16] Safe-Control-Gym: A Unified Benchmark Suite for Safe Learning-Based Control and Reinforcement Learning in Robotics

IEEE Robotics and Automation Letters, 2022, 正式发表。

阅读重点：控制与 RL 统一评测。借鉴扰动、约束、样本效率及轨迹误差的报告方式；完整 PyBullet 环境为独立扩展。

[R26] SafeFlowMatcher: Safe and Fast Planning using Flow Matching with Control Barrier Functions

ICLR, 2026, 正式发表。

阅读重点：流采样中的安全校正。读 CBF 预测校正及假设；理解为什么更快采样仍可能产生不可行航路，该文提供安全规划方法，本身不进行奖励驱动的策略更新。

06 多无人机协同航路与信用分配

一、任务与环境

通过多智能体强化学习解决协同到达、避碰与信用分配问题，比较个体学习和团队学习。

实验环境：现有 MultiUAVGrid 两机同步三维网格，动作为离散位移。

可选择精读 [R28] QMIX 与 [R63] 多机避碰，比较价值分解和共享策略的协作机制；[R30] 为调度拓展，[R31] 为对抗背景，不作为合作信用分配的直接依据。




图 06：本题课程方案示意。箭头表示训练时的信息流；独立测试时冻结策略。

精读与比较提示（供参考）：

1. 解释独立学习的非平稳性与团队信用分配；给出一个个体短期收益与团队成功相冲突的例子。
2. 比较 QMIX 的单调价值分解与多机避碰论文的共享策略；说明团队信用分配与碰撞课程训练解决的问题有何不同。
3. 区分集中训练和分散执行的信息；说明局部观测、合法动作掩码、完成标记和团队奖励如何进入更新。

应用方案提示（也可选择论文改进）：

1. 画双机交叉通道或协同决策图，说明各机观测、动作和团队奖励，以及 VDN 怎样分配团队价值。
2. 以 IQL 为对照，比较团队完成率与碰撞率；指出同步动作或观测信息中的一项实现条件。

二、训练设置（Bonus）

算法：IQL 训练 + VDN 或带通信的强化学习策略训练。

训练参数：各智能体 Q 函数与 VDN 聚合；或带通信的可训练策略/价值函数。

状态与动作：各无人机局部位置、目标和可见邻机；集中训练信息与执行信息分别说明。各无人机离散移动/等待动作。

奖励与终止：团队完成收益 - 碰撞、耗时与能耗；团队奖励每时刻只记一次。全体完成或联合失败终止；联合步数上限截断。

三、平台实现（Bonus）

1. 训练 IQL 基线，再完成 VDN 或带通信的强化学习策略。采用通信方案时，通信模块须参与奖励驱动的训练。
2. 明确集中训练与分散执行各能使用哪些信息，固定同格碰撞和对向交换碰撞的判定规则。
3. 比较个体奖励与共享奖励，或移除通信、价值分解中的一个组件，分析对协同到达的影响。
4. 按同一时刻存储联合转移，分别处理单机完成、全队完成和时间截断；提交掩码检查及奖励累计检查结果。
5. 给出两机轨迹图和时序占用图；至少展示一次通过等待化解冲突，以及一次协同失败的原因分析。

四、对照实验（Bonus）

IQL 个体/共享奖励、VDN 或通信改进；固定同格和对向交换碰撞规则。

报告指标：团队成功率、碰撞事件每回合、团队电量、联合步数；另附训练回报、损失与计算预算。

选做实现：每个学习方法至少 3 个独立训练种子，每个模型至少 30 个测试回合；三组复评不等于三次训练。固定数据划分与预算，测试集不调参；传统算法另计搜索成本。失败计入完成率，误差/长度注明失败处理。

五、代码起点（Bonus）

环境包提供双机同步网格环境、奖励与冲突检查；IQL、VDN 或通信策略训练由学生实现。默认示例只检查环境，policy.py 留待实现；运行通过不代表作业完成。

下载本题实践包

课程汇报 (Presentation)

汇报内容与 PPT: 完成一次课程汇报, 并提交对应 PPT (PPTX 及同版 PDF)。汇报以文献阅读与方案分析为主: 自行选择与本题相关的至少 2 篇论文精读, 每篇均须实际使用强化学习, 重点比较两篇论文; 方案分析可结合本题应用要求提出方案, 或说明所读论文方案的问题与可完善之处, 任选一个方向。PPT 页数与结构自定。汇报要求见第2页, 评分见第3页。

可选提交: 平台实现 (Bonus)。可在课程汇报之外提交平台实现, 包括可运行代码、环境配置、训练参数与日志、随机种子和测试结果, 并注明个人实现与复用部分。实现结果由平台统一复评, 作为额外加分依据。

汇报评分: 文献阅读 85%, 方案分析 15%; 平台实现为可选 Bonus, 未提交不影响汇报成绩。

参考文献 (推荐清单, 可自行另选)

强化学习论文 (可供精读比较)

[R28] QMIX: Monotonic Value Function Factorisation for Deep Multi-Agent Reinforcement Learning

ICML, 2018, 正式发表。

阅读重点: 单调混合与集中训练。重点读单调性限制和状态条件混合网络; 解释何时 VDN 表达能力不足。

[R63] Collision Avoidance and Navigation for a Quadrotor Swarm Using End-to-end Deep Reinforcement Learning

ICRA, 2024, 正式发表。

阅读重点: 端到端多机避碰 RL、课程学习与碰撞样本利用。关注邻机观测、共享策略和稀有碰撞; 比较训练规模与部署规模变化。

[R27] Value-Decomposition Networks For Cooperative Multi-Agent Learning Based On Team Reward

AAMAS, 2018, 正式扩展摘要。

阅读重点: 加性价值分解。读团队 Q 值分解; 比较共享奖励 IQL 和 VDN, 分析个体效用与团队回报的关系。

[R52] The Surprising Effectiveness of PPO in Cooperative Multi-Agent Games

NeurIPS Datasets and Benchmarks, 2022, 正式发表。

阅读重点: 集中训练与分散执行。理解集中 critic、分散 actor、团队回报 GAE 与 PPO 更新, 并比较 IPPO; 联合生成先验属于课程扩展。

[R30] Decentralized Learning-Driven AoI Optimization in UAV-Assisted Wireless Powered Edge Networks

IEEE Transactions on Mobile Computing, 2026, 正式发表。

阅读重点: AoI 与边缘任务调度。阅读 AoI 状态演化与去中心化学习; 新增充电、关联和调度变量后再评价 AoI。

[R31] Securing Integrated Sensing and Communication Against a Mobile Adversary: A Stackelberg Game With Deep Reinforcement Learning

IEEE Journal on Selected Areas in Communications, 2026 卷期, 2025 在线发表。

阅读重点: 移动对手与通信安全。理解 Stackelberg 博弈和对手 UAV 决策; 只借鉴威胁建模, 不将其视为协作 AttnSAC 原文。

07 LLM 任务解析与强化学习工具决策

一、任务与环境

用 LLM 解析任务，用强化学习决定选择、修复、执行或拒绝，使工具决策在调用预算内服务于任务完成。

实验环境：UAV01 三维电量网格；LLM 输出访问点顺序与返航标志，A* 生成位移指令。仅在仿真执行。

可选择精读 [R65] CodeGym 与 [R66] ResT，比较工具环境、奖励和策略梯度；论文直接训练 LLM，本题可用固定 LLM 加 DQN 选择器降低实现成本。




图 07：本题课程方案示意。箭头表示训练时的信息流；独立测试时冻结策略。

精读与比较提示（供参考）：

1. 解释 ReAct 中推理与工具调用的关系；指出其哪些环节没有通过任务奖励更新参数，不能直接视为强化学习。
2. 说明 DQN 怎样学习多步工具决策；定义工具执行前后的状态、动作和回报，解释为何不能只学习一次静态分类。
3. 比较 LLM 建议、规则规划与奖励训练策略的职责；分析无效输出、重复调用和任务不可达的处理方式。

应用方案提示（也可选择论文改进）：

1. 画“LLM 建议—DQN 选工具—仿真执行”流程，给出一个工具选择例子，说明完成收益和调用代价。
2. 以固定 LLM 建议直接执行为对照，比较任务成功率与工具调用次数；简述可用的仿真工具。

二、训练设置（Bonus）

算法：冻结 LLM + DQN 多步工具决策策略；不要求训练大语言模型权重。

训练参数：小型任务决策 Q 网络及目标网络；LLM 与文本编码器保持冻结。工具合同随实践包提供，固定候选数、合法动作、费用及拒绝判定。

状态与动作：指令文本嵌入、任务进度、电量、候选结构和已发生的验证器反馈；隐藏答案不进入观测。选择候选、请求一次受限修复、执行下一子任务或拒绝/结束；动作受合法工具白名单约束。

奖励与终止：按指令完成的终局收益 - 错误执行/违规惩罚 - 调用与时间成本；拒绝所有任务不能获得高收益。任务完成、失败或拒绝终止；预算作为有限任务状态，耗尽判失败终止。拒绝由独立可行性判定计分，不能靠全部拒绝获益。

三、平台实现（Bonus）

1. 固定 LLM 参数，训练 DQN 完成候选选择、受限修复、执行或拒绝等多步工具决策。
2. 用任务执行结果计算奖励；语义标签用于奖励和评估，不得作为候选选择时的输入。
3. 在相同 LLM 调用上限下比较规则解析、固定验证流程和 DQN 决策，按任务模板划分测试集。
4. 固定模型版本、提示词和采样设置，保存请求、工具参数与执行结果；训练 DQN 时冻结 LLM 权重。
5. 提交多步回放轨迹和 DQN 训练曲线，分别测试无效建议、障碍变化和预算不足；只在课程仿真工具中执行。

四、对照实验（Bonus）

规则解析、冻结 LLM+ 固定验证流程、LLM+DQN；相同 LLM 调用上限，按任务模板留出测试。

报告指标：结构合格率、语义准确率、任务完成率、正确拒绝率、模型调用数、端到端时延；另附训练回报、损失与计算预算。

选做实现：每个学习方法至少 3 个独立训练种子，每个模型至少 30 个测试回合；三组复评不等于三次训练。固定数据划分与预算，测试集不调参；传统算法另计搜索成本。失败计入完成率，误差/长度注明失败处理。

五、代码起点 (Bonus)

环境包提供任务验证、传统规划工具和动作合同；DQN 工具决策训练由学生实现。默认示例只检查环境，policy.py 留待实现；运行通过不代表作业完成。

下载本题实践包

课程汇报 (Presentation)

汇报内容与 PPT：完成一次课程汇报，并提交对应 PPT (PPTX 及同版 PDF)。汇报以文献阅读与方案分析为主：自行选择与本题相关的至少 2 篇论文精读，每篇均须实际使用强化学习，重点比较两篇论文；方案分析可结合本题应用要求提出方案，或说明所读论文方案的问题与可完善之处，任选一个方向。PPT 页数与结构自定。汇报要求见第2页，评分见第3页。

可选提交：平台实现 (Bonus)。可在课程汇报之外提交平台实现，包括可运行代码、环境配置、训练参数与日志、随机种子和测试结果，并注明个人实现与复用部分。实现结果由平台统一复评，作为额外加分依据。

汇报评分：文献阅读 85%，方案分析 15%；平台实现为可选 Bonus，未提交不影响汇报成绩。

参考文献 (推荐清单，可自行另选)

强化学习论文 (可供精读比较)

[R65] Generalizable End-to-End Tool-Use RL with Synthetic CodeGym

ICLR, 2026, 正式发表。

阅读重点：构建可执行、可验证的多轮工具环境训练 LLM。重点比较奖励来源、交互轨迹与未见工具泛化；分析其与本题固定 LLM 加 DQN 选择器的差别。

[R66] ResT: Reshaping Token-Level Policy Gradients for Tool-Use Large Language Models

ICLR, 2026, 正式发表。

阅读重点：依据 token 熵重加权工具调用的策略梯度，处理稀疏结果奖励。与 CodeGym 比较环境设计和更新机制；不将提示词改写视为 RL 训练。

[R02] Human-level control through deep reinforcement learning

Nature, 2015, 正式发表。

阅读重点：奖励驱动的离散价值学习。理解 Q 网络、经验回放、目标网络与 TD 更新的作用；讨论本题状态、合法动作和奖励的定义。

[R33] Do As I Can, Not As I Say: Grounding Language in Robotic Affordances

CoRL 2022; PMLR 论文集 2023, 正式发表。

阅读重点：语言与可执行性结合。读语言分数和技能可执行性组合；将候选任务步骤交给规则/路径规划工具检验。

背景参考 (不计入两篇精读论文)

[R32] ReAct: Synergizing Reasoning and Acting in Language Models

ICLR, 2023, 正式发表。

阅读重点：工具调用与观察反馈。读推理-动作-观察循环；规划器生成结构化工具调用并保留执行日志。

[R35] An LLM-Agnostic, MAVLink-Based Drone Command and Control Interface and Agentic Harness Using the Model Context Protocol

arXiv, 2026, 预印本。

阅读重点：真实无人机协议接口。阅读 MAVLink 工具与代理接口；在独立 PX4/SITL 扩展验证，当前作业仍先用本地仿真工具。

08 扩散航路生成与 DPPO 强化学习微调

一、任务与环境

先学习专家航路分布，再用航路执行评价奖励微调扩散策略，研究可行率、长度和多样性的变化。

实验环境：新增 8×8 定高几何赛道，条件为地图、起点与终点，输出 24 个二维航点；无动力学，不能按真实飞行控制评分。

可比较 [R38] DPPO 与 [R08] PPO，分析扩散策略如何接受奖励驱动更新；也可自选其他扩散强化学习论文。其余生成与规划资料作为背景。




图 08：本题课程方案示意。箭头表示训练时的信息流；独立测试时冻结策略。

精读与比较提示（供参考）：

1. 写出加噪过程与噪声预测损失；说明地图和端点怎样作为条件，为什么去噪损失更小不等于任务回报更高。
2. 画出 DPPO 内层去噪与外层环境两个过程；说明旧策略概率、优势和裁剪目标怎样对应去噪动作。
3. 区分条件生成、代价引导、筛选回退和策略梯度微调；指出哪些机制真正改变了生成策略参数。

应用方案提示（也可选择论文改进）：

1. 画“DDPM 预训练—DPPO 微调—航路评估”流程，说明地图条件、航路输出和任务奖励。
2. 以纯 DDPM 为对照，比较原始航路可行率与路径长度；简述专家航路如何获得。

二、训练设置（Bonus）

算法：DDPM 条件航路预训练 + 借鉴 DPPO 的策略梯度微调；外层为一次完整航路评价，属于课程改编。

训练参数：噪声预测网络 ε_θ ；DPPO 阶段继续更新 ε_θ 并训练价值网络 $V\phi$ 。

状态与动作：场景、起终点与当前带噪轨迹、去噪时间；使用去噪扩展 MDP。每个随机去噪转移的轨迹增量/下一去噪状态；最终输出整条航路。

奖励与终止：最终原始航路的可行奖励 - 碰撞/越界惩罚 - 长度与平滑代价；回退规划器结果不作为生成器奖励。固定去噪链结束后评价原始轨迹并终止；交互预算用场景评价次数与去噪步数分别统计。

三、平台实现（Bonus）

1. 训练条件 DDPM，再按 DPPO 对去噪网络进行强化学习微调，保存两个阶段的模型。
2. 实现随机去噪转移概率、旧策略比率与裁剪目标；固定端点不计入随机动作维度。确定性步骤不能直接套用高斯 PPO 概率。
3. 固定候选数量与去噪预算，比较预训练和微调后的航路；原始生成、筛选和回退结果分别统计。
4. 提交预训练及微调参数、去噪链采样记录和奖励曲线；证明奖励驱动更新发生，不能仅在多个候选中挑选最优。
5. 展示同一地图多条原始样本、微调后样本及失败航路；按整张地图划分数据，禁止测试地图泄漏到专家训练集。

四、对照实验（Bonus）

BFS、BC、DDPM 预训练、DDPM+DPPO；固定训练场景、候选数及去噪预算，原始/筛选/回退分开。

报告指标：原始可行率、碰撞与越界率、路径长度、通道覆盖或多样性、筛选后可行率、传统回退率、生成与验证时延；另附训练回报、损失与计算预算。

选做实现：每个学习方法至少 3 个独立训练种子，每个模型至少 30 个测试回合；三组复评不等于三次训练。固定数据划分与预算，测试集不调参；传统算法另计搜索成本。失败计入完成率，误差/长度注明失败处理。

五、代码起点 (Bonus)

环境包提供几何场景、专家路径工具与碰撞检查；DDPM 预训练和 DPPO 微调由学生实现。默认示例只检查环境，policy.py 留待实现；运行通过不代表作业完成。

下载本题实践包

课程汇报 (Presentation)

汇报内容与 PPT：完成一次课程汇报，并提交对应 PPT (PPTX 及同版 PDF)。汇报以文献阅读与方案分析为主：自行选择与本题相关的至少 2 篇论文精读，每篇均须实际使用强化学习，重点比较两篇论文；方案分析可结合本题应用要求提出方案，或说明所读论文方案的问题与可完善之处，任选一个方向。PPT 页数与结构自定。汇报要求见第2页，评分见第3页。

可选提交：平台实现 (Bonus)。可在课程汇报之外提交平台实现，包括可运行代码、环境配置、训练参数与日志、随机种子和测试结果，并注明个人实现与复用部分。实现结果由平台统一复评，作为额外加分依据。

汇报评分：文献阅读 85%，方案分析 15%；平台实现为可选 Bonus，未提交不影响汇报成绩。

参考文献 (推荐清单，可自行另选)

强化学习论文 (可供精读比较)

[R38] Diffusion Policy Policy Optimization

ICLR, 2025, 正式发表。

阅读重点：扩散策略的强化学习微调。重点阅读去噪扩展 MDP、随机转移 log 概率、策略梯度与预训练/微调对照；不要将 DDPM 噪声 MSE 称为 RL。

[R08] Proximal Policy Optimization Algorithms

arXiv, 2017, 算法原始预印本。

阅读重点：裁剪策略梯度与优势估计。理解 PPO 采样、旧策略概率、GAE 和 actor/critic 更新；解读样本效率、回报与留出场景表现。

背景参考 (不计入两篇精读论文)

[R42] AeroDiffusion: Real-Time Quadrotor Trajectory Planning in Dynamic Environments via Conditional Diffusion

IEEE Robotics and Automation Letters, 2026, 正式发表。

阅读重点：无人机条件扩散与闭环重规划。阅读状态/深度条件、候选筛选和热启动去噪；当前作业先做几何规划，增加视觉与动力学后再做论文级闭环复现。

[R41] Motion Planning Diffusion: Learning and Adapting Robot Motion Planning with Diffusion Models

IEEE Transactions on Robotics, 2025, 正式发表。

阅读重点：轨迹先验与约束代价引导。重点读 B-spline 轨迹表示和去噪中的代价梯度；分析障碍代价引导与条件网络的作用及局限。

[R39] Denoising Diffusion Probabilistic Models

NeurIPS, 2020, 正式发表。

阅读重点：噪声回归与逆向去噪原理。理解噪声预测 MSE 和逆向采样；可作为扩散模型的基础阅读。

[R40] Planning with Diffusion for Flexible Behavior Synthesis

ICML, 2022, 正式发表。

阅读重点：条件轨迹扩散规划。重点读轨迹去噪、起终点条件与代价引导；明确每次采样输出整段航路。

09 Flow Matching 与 FQL 无人机航路强化学习

一、任务与环境

将流匹配得到的行为先验接入离线价值学习，通过一步策略改进得到具有任务回报目标的航路策略。

实验环境：与 UAV08 共享定高地图，但训练采用逐航段接口：每步执行一个有界连续航点，产生奖励和下一状态；最终适配为 24 个航点提交复评。

可比较 [R45] FQL 与 [R11] SAC 的价值学习、策略改进和数据条件；也可自选其他流策略强化学习论文。Flow Matching 与安全校正资料作为背景。




图 09：本题课程方案示意。离线数据驱动训练；独立测试结果不回流训练。

精读与比较提示（供参考）：

1. 写出线性插值、目标速度和流匹配损失；区分生成时间与环境时间，并解释独立数据配对不等于最优传输。
2. 说明 FQL 的流行为先验、Q 学习和一步策略蒸馏各自作用；解释为什么只训练速度场还没有进行强化学习。
3. 分析离线数据覆盖不足与价值高估；说明终止、截断和下一状态字段为什么会直接影响 TD 目标。

应用方案提示（也可选择论文改进）：

1. 画“离线数据—流先验与 FQL—冻结评测”流程，说明奖励、下一状态和 Q 学习的作用。
2. 以纯 CFM 为对照，比较航路可行率与任务回报；简述离线数据来源及覆盖不足的风险。

二、训练设置（Bonus）

算法：条件 Flow Matching 行为先验 + Flow Q-Learning (FQL) 离线强化学习。

训练参数：流速度网络 v_η ；双 Q 网络；一步策略 $a_\psi(s, z)$ 及目标网络。

状态与动作：当前位置、目标、地图及剩余步数；一个连续局部航点。统一航段碰撞与奖励规则；训练接口与整条航路提交适配器见实践包。

奖励与终止：进展/到达收益 - 碰撞、越界、长度及能耗代价；离线数据含成功与失败转移。到达/任务失败终止；环境步数预算耗尽判失败终止；采样器中断另记截断，非终端片段不得误标终止。

三、平台实现（Bonus）

1. 构建含奖励、下一状态及终止标记的离线转移数据，保留成功和失败样本。
2. 训练流行为先验、双 Q 网络和一步策略，完成 FQL 更新；记录各项损失和策略回报。
3. 在同一数据集上比较 BC、CFM 和 FQL，并对 Q 引导或行为正则做消融。
4. 训练阶段禁止使用测试交互补充离线集；提交数据摘要、成功/失败比例、终止字段检查和全部模型参数。
5. 记录 TD 损失、流匹配损失、策略损失及独立评测回报；去除 Q 项或改变正则强度，分析数据外动作和失败变化。

四、对照实验（Bonus）

BC、纯 CFM、CFM+FQL；Q 引导/行为正则消融，相同离线转移集和评测预算。

报告指标：任务完成率、回报、原始航路可行率、路径长度与端到端时延；分别报告 CFM 的 ODE 评估次数和 FQL 一步策略查询次数，回退另记。

选做实现：每个学习方法至少 3 个独立训练种子，每个模型至少 30 个测试回合；三组复评不等于三次训练。固定数据划分与预算，测试集不调参；传统算法另计搜索成本。失败计入完成率，误差/长度注明失败处理。

五、代码起点 (Bonus)

环境包提供几何场景、逐航点环境和航路提交适配器；流先验与 FQL 训练由学生实现。默认示例只检查环境，policy.py 留待实现；运行通过不代表作业完成。

下载本题实践包

课程汇报 (Presentation)

汇报内容与 PPT：完成一次课程汇报，并提交对应 PPT (PPTX 及同版 PDF)。汇报以文献阅读与方案分析为主：自行选择与本题相关的至少 2 篇论文精读，每篇均须实际使用强化学习，重点比较两篇论文；方案分析可结合本题应用要求提出方案，或说明所读论文方案的问题与可完善之处，任选一个方向。PPT 页数与结构自定。汇报要求见第2页，评分见第3页。

可选提交：平台实现 (Bonus)。可在课程汇报之外提交平台实现，包括可运行代码、环境配置、训练参数与日志、随机种子和测试结果，并注明个人实现与复用部分。实现结果由平台统一复评，作为额外加分依据。

汇报评分：文献阅读 85%，方案分析 15%；平台实现为可选 Bonus，未提交不影响汇报成绩。

参考文献 (推荐清单，可自行另选)

强化学习论文 (可供精读比较)

[R45] Flow Q-Learning

ICML, 2025, 正式发表。

阅读重点：Flow Matching 与离线强化学习。理解带奖励的转移数据、双 Q TD 学习、流行为先验与一步策略蒸馏/Q 改进；区分 CFM 预训练与强化学习。

[R11] Soft Actor-Critic: Off-Policy Maximum Entropy Deep Reinforcement Learning with a Stochastic Actor

ICML, 2018, 正式发表。

阅读重点：最大熵强化学习与残差控制。理解双 Q、目标网络、回放与随机策略更新；分析残差控制如何通过组合动作获得环境回报。

背景参考 (不计入两篇精读论文)

[R26] SafeFlowMatcher: Safe and Fast Planning using Flow Matching with Control Barrier Functions

ICLR, 2026, 正式发表。

阅读重点：流采样中的安全校正。读 CBF 预测校正及假设；理解为什么更快采样仍可能产生不可行航路，该文提供安全规划方法，本身不进行奖励驱动的策略更新。

[R22] Flow Matching for Generative Modeling

ICLR, 2023, 正式发表。

阅读重点：条件速度场与 ODE。理解线性插值、速度监督目标与 ODE 采样；区分独立配对与最优传输。

[R46] Flow Straight and Fast: Learning to Generate and Transfer Data with Rectified Flow

ICLR, 2023, 正式发表。

阅读重点：直线路径与少步生成。读整流思想与离散积分误差；比较 Euler/Heun 在相同 NFE 下的性能。

[R14] FlowPilot: Real-Time World-Action Modeling for Agile UAV Navigation

arXiv, 2026, 预印本。

阅读重点：无人机世界动作模型。阅读深度与轨迹双流建模；视觉导航方向作为新增环境拓展。

10 生成式动作分块与残差强化学习飞行控制

一、任务与环境

以生成式动作块提供基础控制，通过强化学习残差提高闭环跟踪和扰动适应能力。

实验环境：UAV03 相同平面刚体，输出未来 4 步总推力和俯仰力矩；滚动执行，动作限幅、仿真步长 0.02 秒固定；50Hz 仿真不等于实际推理已达实时。

可选择精读 [R57] Policy Decorator 与 [R67] DSRL，比较动作残差与噪声空间 RL；[R68] 补充带信赖域约束的潜空间改进。




图 10：本题课程方案示意。箭头表示训练时的信息流；独立测试时冻结策略。

精读与比较提示（供参考）：

1. 解释动作分块与滚动执行；说明预测长度、实际执行长度和重规划频率怎样影响延迟及误差累积。
2. 说明生成模型的模仿损失与 SAC 奖励目标的差别；解释为什么模仿动作块之后还需要闭环残差学习。
3. 分析残差作用于整个动作块或当前动作的差异；讨论执行限幅、状态过时及控制不平滑的影响。

应用方案提示（也可选择论文改进）：

1. 画“生成动作块—SAC 残差—滚动执行”流程，说明动作块内容、残差和控制奖励。
2. 以纯生成动作块为对照，比较跟踪误差与失稳率；简述控制频率或推理时延的一项限制。

二、训练设置（Bonus）

算法：DDPM 或 CFM 动作块预训练（至少一种）+ SAC 残差强化学习。

训练参数：DDPM 或 CFM 生成网络；SAC 残差策略、双 Q 与目标网络。

状态与动作：飞行状态/历史、参考轨迹、生成式基础动作及块内相位。逐控制步的有界残差 δu ；与生成动作相加后统一限幅。

奖励与终止：负跟踪误差、失稳、能耗和残差幅值代价；连续闭环环境给出反馈。失稳/越界终止；固定时长截断；动作块内提前失败必须正确截断。

三、平台实现（Bonus）

1. 选择 DDPM 或 CFM 完成动作块预训练，固定生成器后训练 SAC 残差策略。
2. 在连续闭环环境中执行基础动作与残差的叠加，记录限幅、残差幅值及跟踪误差。
3. 比较每执行 1、2、4 步后重新规划的效果；奖励设置、数据量和环境交互预算保持一致。
4. 提交纯生成与生成加 SAC 两套控制记录，保存生成块、残差和实际执行动作；延迟测试包含生成和控制全过程，注明硬件；实时扩展固定 20 毫秒截止，超时使用安全备用动作并计入超时率。
5. 在相同参考轨迹下展示跟踪曲线，增加缩小/去除残差的消融；解释动作块更长时可能出现的过时控制。

四、对照实验（Bonus）

PID、BC、生成式预训练、生成式 +SAC；执行 1/2/4 步再重规划，奖励与数据/交互预算固定。

报告指标：位置 RMSE、失稳率、回合完成比例、动作饱和比例、推力变化、策略查询时延；另附训练回报、损失与计算预算。

选做实现：每个学习方法至少 3 个独立训练种子，每个模型至少 30 个测试回合；三组复评不等于三次训练。固定数据划分与预算，测试集不调参；传统算法另计搜索成本。失败计入完成率，误差/长度注明失败处理。

五、代码起点（Bonus）

环境包提供二维动力学、动作接口与传统示范工具；生成动作块及 SAC 残差训练由学生实现。默认示例只检查环境，policy.py 留待实现；运行通过不代表作业完成。

下载本题实践包

课程汇报 (Presentation)

汇报内容与 PPT: 完成一次课程汇报, 并提交对应 PPT (PPTX 及同版 PDF)。汇报以文献阅读与方案分析为主: 自行选择与本题相关的至少 2 篇论文精读, 每篇均须实际使用强化学习, 重点比较两篇论文; 方案分析可结合本题应用要求提出方案, 或说明所读论文方案的问题与可完善之处, 任选一个方向。PPT 页数与结构自定。汇报要求见第2页, 评分见第3页。

可选提交: 平台实现 (Bonus)。可在课程汇报之外提交平台实现, 包括可运行代码、环境配置、训练参数与日志、随机种子和测试结果, 并注明个人实现与复用部分。实现结果由平台统一复评, 作为额外加分依据。

汇报评分: 文献阅读 85%, 方案分析 15%; 平台实现为可选 Bonus, 未提交不影响汇报成绩。

参考文献 (推荐清单, 可自行另选)

强化学习论文 (可供精读比较)

[R57] Policy Decorator: Model-Agnostic Online Refinement for Large Policy Model

ICLR, 2025, 正式发表。

阅读重点: 冻结模仿策略, 以 SAC 训练残差策略并限制早期探索。区分示范预训练与在线奖励更新; 原文为机器人操作, 飞行应用需调整动作和安全边界。

[R67] Steering Your Diffusion Policy with Latent Space Reinforcement Learning

CoRL, 2025, 正式发表 (DSRL)。

阅读重点: 冻结扩散策略, 在输入噪声空间学习 RL 策略。与动作残差比较优化变量、探索范围和样本效率; 原文操作任务向飞行任务迁移需重新定义反馈。

[R68] Lagrangian Perturbation Diffusion Steering: Latent Reinforcement Learning for Generative Policies

ICML, 2026, 正式发表 (LP-DS)。

阅读重点: 在冻结生成策略前学习噪声扰动, 以拉格朗日信赖域限制先验偏离。比较约束与无约束潜空间 RL, 并讨论扩散和流策略中的适用条件。

[R11] Soft Actor-Critic: Off-Policy Maximum Entropy Deep Reinforcement Learning with a Stochastic Actor

ICML, 2018, 正式发表。

阅读重点: 最大熵强化学习与残差控制。理解双 Q、目标网络、回放与随机策略更新; 分析残差控制如何通过组合动作获得环境回报。

[R15] Learning to Fly in Seconds

IEEE Robotics and Automation Letters, 2024, 正式发表。

阅读重点: 四旋翼 RL 训练与 Sim2Real。读强化学习控制器、训练随机化和快速动力学仿真; 借鉴训练组织方式, 避免照搬训练时间结论。

背景参考 (不计入两篇精读论文)

[R12] Diffusion Policy: Visuomotor Policy Learning via Action Diffusion

RSS, 2023, 正式发表。

阅读重点: 多模态动作模仿。阅读条件动作去噪; 作为生成式模仿扩展, 比较不同可行绕障路线。

11 语言条件生成策略与强化学习任务适配

一、任务与环境

根据自然语言任务训练条件决策策略，研究奖励驱动的任务适配与未见表达泛化。

实验环境：UAV03 平面模型。基础方案使用悬停、向左、向右任务 ID；自然语言编码、未见表达及任务组合为扩展，按方案分开评测。

可比较 [R69] 残差 RL 改进 VLA 与 [R57] Policy Decorator 的奖励更新和残差机制；也可自选相关 RL 论文。语言条件预训练资料作为背景。




图 11：本题课程方案示意。箭头表示训练时的信息流；独立测试时冻结策略。

精读与比较提示（供参考）：

1. 说明语言或任务标签怎样进入生成策略；区分固定任务 ID、文本编码与视觉语言动作模型，避免混称能力。
2. 分析生成先验如何与 PPO 残差结合；指出策略概率、优势估计和任务奖励对应哪些可训练参数。
3. 区分同一指令改写、已知任务组合与新任务泛化；解释为什么随机划分同义句可能造成评测泄漏。

应用方案提示（也可选择论文改进）：

1. 画“任务条件—生成先验—PPO 残差”流程，用悬停或左右移动举例说明条件、动作与奖励。
2. 以未经 PPO 微调的条件先验为对照，比较任务完成率与误执行率；基础方案可只使用任务标签。

二、训练设置（Bonus）

算法：任务条件 BC/CFM 预训练 + 条件 PPO 残差；基础方案使用任务 ID，自然语言扩展使用冻结文本编码器。

训练参数：条件动作生成网络、PPO 残差策略与条件价值网络；文本编码器仅在自然语言扩展中使用并冻结。

状态与动作：飞行状态、参考信息、合法任务 ID（或文本编码）及生成基础动作。允许输入用户任务条件；禁止输入隐藏成功标签、未来轨迹及评测答案。动作是限幅前的连续残差。

奖励与终止：针对指令任务定义完成收益与跟踪、能耗、安全代价；错误任务执行不给成功奖励。指令任务完成/失败终止；时长或工具预算截断。

三、平台实现（Bonus）

1. 完成任务 ID 条件 BC 或 CFM 预训练，冻结生成器后训练 PPO 残差；自然语言编码器为选做扩展。
2. 按指令完成的任务计算奖励，检查错误任务执行是否被误计为成功；用户给定任务 ID 可以输入，隐藏评测答案不得输入。
3. 基础方案做去除或交换任务 ID 的消融；未见同义表达及任务组合仅用于自然语言扩展。
4. 保留预训练与 PPO 参数，分别按任务报告结果；增加交换任务标签的测试，验证策略确实使用条件而非固定动作。
5. 若实现自然语言扩展，应按表达模板或任务组合划分留出集；不能将标签识别或语言流畅度代替任务执行成绩。

四、对照实验（Bonus）

固定任务策略、条件生成基线、条件先验 +PPO；基础方案比较正确/去除/交换 ID，自然语言扩展另测留出表达和任务组合。

报告指标：任务完成率、位置 RMSE、失稳率、条件置换敏感性、推理成本；另附训练回报、损失与计算预算。

选做实现：每个学习方法至少 3 个独立训练种子，每个模型至少 30 个测试回合；三组复评不等于三次训练。固定数据划分与预算，测试集不调参；传统算法另计搜索成本。失败计入完成率，误差/长度注明失败处理。

五、代码起点 (Bonus)

环境包提供任务标签、条件观测与二维动力学；条件预训练及 PPO 残差由学生实现，自然语言扩展选做。默认示例只检查环境，policy.py 留待实现；运行通过不代表作业完成。

下载本题实践包

课程汇报 (Presentation)

汇报内容与 PPT：完成一次课程汇报，并提交对应 PPT (PPTX 及同版 PDF)。汇报以文献阅读与方案分析为主：自行选择与本题相关的至少 2 篇论文精读，每篇均须实际使用强化学习，重点比较两篇论文；方案分析可结合本题应用要求提出方案，或说明所读论文方案的问题与可完善之处，任选一个方向。PPT 页数与结构自定。汇报要求见第2页，评分见第3页。

可选提交：平台实现 (Bonus)。可在课程汇报之外提交平台实现，包括可运行代码、环境配置、训练参数与日志、随机种子和测试结果，并注明个人实现与复用部分。实现结果由平台统一复评，作为额外加分依据。

汇报评分：文献阅读 85%，方案分析 15%；平台实现为可选 Bonus，未提交不影响汇报成绩。

参考文献 (推荐清单，可自行另选)

强化学习论文 (可供精读比较)

[R69] Self-Improving Vision-Language-Action Models with Data Generation via Residual RL

ICLR, 2026, 正式发表。

阅读重点：通过残差 RL 改进冻结 VLA 并生成数据，再蒸馏到基础策略。分别说明 RL 奖励更新与监督蒸馏，比较对示范数据和环境交互的依赖。

[R57] Policy Decorator: Model-Agnostic Online Refinement for Large Policy Model

ICLR, 2025, 正式发表。

阅读重点：冻结模仿策略，以 SAC 训练残差策略并限制早期探索。区分示范预训练与在线奖励更新；原文为机器人操作，飞行应用需调整动作和安全边界。

[R08] Proximal Policy Optimization Algorithms

arXiv, 2017, 算法原始预印本。

阅读重点：裁剪策略梯度与优势估计。理解 PPO 采样、旧策略概率、GAE 和 actor/critic 更新；解读样本效率、回报与留出场景表现。

背景参考 (不计入两篇精读论文)

[R47] π_0 : A Vision-Language-Action Flow Model for General Robot Control

RSS, 2025, 正式发表。

阅读重点：视觉语言条件与 Flow 动作头。重点读语言视觉表征和 Flow Matching 动作生成；先借鉴语言条件动作头，逐步适配飞行动作。

[R50] OpenVLA: An Open-Source Vision-Language-Action Model

CoRL 2024; PMLR 论文集 2025, 正式发表。

阅读重点：开源 VLA 与高效微调。关注视觉语言融合和 LoRA/微调流程；按硬件预算选择冻结表征或参数高效适配。

[R49] Octo: An Open-Source Generalist Robot Policy

RSS, 2024, 正式发表。

阅读重点：通用条件策略与适配。读任务 token、扩散动作头和微调；分析论文对未见表达和任务组合的适配能力。

12 生成式多无人机航路与 MAPPO 协同强化学习

一、任务与环境

在联合生成的航路先验上训练多机协同策略，研究集中价值学习对避碰、协同与任务完成的作用。

实验环境：8×8 两机定高几何赛道；训练时同步执行一段并检查同时间机间距离，最终输出 32 个同步航点。与 UAV06 分开评测。

可比较 [R63] 多机避碰 RL 与 [R64] 结构化多智能体 RL；也可选择 [R52] MAPPO 或其他协同 RL 论文。联合扩散规划和搜索方法作为背景。




图 12：本题课程方案示意。箭头表示训练时的信息流；独立测试时冻结策略。

精读与比较提示（供参考）：

1. 解释联合轨迹生成与逐机独立生成的区别；分析只检查单机避障为何仍可能出现机间碰撞。
2. 说明 MAPPO 集中 critic 与分散 actor 各能访问哪些信息；解释团队优势、完成标记和存活掩码的作用。
3. 区分生成时约束投影与执行时 RL 修正；说明投影、筛选和回退如何影响奖励归因及计算预算。

应用方案提示（也可选择论文改进）：

1. 画双机联合航路与 MAPPO 修正框图，说明各机动作、团队奖励及集中 critic 的作用。
2. 以联合生成加 IPPO 为对照，比较团队完成率与最小机间距离；简述同步执行这一实现条件。

二、训练设置（Bonus）

算法：联合 DDPM 或 CFM 先验 + MAPPO 协同残差强化学习。

训练参数：联合 DDPM 或 CFM 生成器；各机/共享 actor 与集中价值网络。

状态与动作：每架机位置、目标、邻机及生成先验建议；集中价值网络可用联合状态，执行 actor 只用声明的局部/通信信息。联合生成器在协调端读取全局场景并下发建议，属于集中规划辅助的分散控制。各无人机局部航点修正或有界残差；同步执行产生联合转移。

奖励与终止：团队完成收益 - 同格/交换/交叉碰撞 - 总路程/等待与任务遗漏；不重复累计团队奖励。团队完成或任务失败终止；步数预算耗尽判失败终止，记录每机完成掩码；到达者停留占位，仍参与碰撞检查。

三、平台实现（Bonus）

1. 训练联合 DDPM 或 CFM 先验，固定先验后，用团队回报训练 MAPPO 的分散策略和集中价值网络。
2. 说明执行时允许使用的局部或通信信息，检查团队奖励、碰撞、终止、截断和存活掩码的处理。
3. 比较独立生成、联合生成、IPPO 及 MAPPO，并对集中价值网络或邻机信息做消融。
4. 提交同步联合转移与分机掩码检查，使用线段级连续碰撞检测；不能只检测离散航点而漏掉交叉航段冲突。
5. 给出两机同步轨迹图，比较无集中 critic 或去除邻机信息的结果；报告原始样本与回退后的完成率及总代价。

四、对照实验（Bonus）

独立生成、联合生成、联合生成 + IPPO、联合生成 + MAPPO；相同交互预算，集中 critic/邻机信息消融。

报告指标：团队可行率、最小间距、碰撞时间段、联合路径长度、任务完成率、回退率、生成与验证时延；另附训练回报、损失与计算预算。

选做实现：每个学习方法至少 3 个独立训练种子，每个模型至少 30 个测试回合；三组复评不等于三次训练。固定数据划分与预算，测试集不调参；传统算法另计搜索成本。失败计入完成率，误差/长度注明失败处理。

五、代码起点 (Bonus)

环境包提供双机场景、同步航点环境与冲突检查；联合生成和 MAPPO 训练由学生实现。默认示例只检查环境，policy.py 留待实现；运行通过不代表作业完成。

下载本题实践包

课程汇报 (Presentation)

汇报内容与 PPT：完成一次课程汇报，并提交对应 PPT (PPTX 及同版 PDF)。汇报以文献阅读与方案分析为主：自行选择与本题相关的至少 2 篇论文精读，每篇均须实际使用强化学习，重点比较两篇论文；方案分析可结合本题应用要求提出方案，或说明所读论文方案的问题与可完善之处，任选一个方向。PPT 页数与结构自定。汇报要求见第2页，评分见第3页。

可选提交：平台实现 (Bonus)。可在课程汇报之外提交平台实现，包括可运行代码、环境配置、训练参数与日志、随机种子和测试结果，并注明个人实现与复用部分。实现结果由平台统一复评，作为额外加分依据。

汇报评分：文献阅读 85%，方案分析 15%；平台实现为可选 Bonus，未提交不影响汇报成绩。

参考文献 (推荐清单，可自行另选)

强化学习论文 (可供精读比较)

[R63] Collision Avoidance and Navigation for a Quadrotor Swarm Using End-to-end Deep Reinforcement Learning
ICRA, 2024, 正式发表。

阅读重点：端到端多机避碰 RL、课程学习与碰撞样本利用。关注邻机观测、共享策略和稀有碰撞；比较训练规模与部署规模变化。

[R64] Physics-Informed Multiagent Reinforcement Learning for Distributed Multirobot Problems
IEEE Transactions on Robotics, 2025, 正式发表。

阅读重点：物理结构与注意力结合的分布式多智能体 RL。比较结构化策略与集中训练；原文机器人实验的动力学与本题飞行环境需分别说明。

[R52] The Surprising Effectiveness of PPO in Cooperative Multi-Agent Games
NeurIPS Datasets and Benchmarks, 2022, 正式发表。

阅读重点：集中训练与分散执行。理解集中 critic、分散 actor、团队回报 GAE 与 PPO 更新，并比较 IPPO；联合生成先验属于课程扩展。

背景参考 (不计入两篇精读论文)

[R53] Simultaneous Multi-Robot Motion Planning with Projected Diffusion Models
ICML, 2025, 正式发表。

阅读重点：联合扩散与约束投影。读联合表示和采样投影；比较独立生成与联合生成的碰撞和任务完成。

[R22] Flow Matching for Generative Modeling
ICLR, 2023, 正式发表。

阅读重点：条件速度场与 ODE。理解线性插值、速度监督目标与 ODE 采样；区分独立配对与最优传输。

[R54] Conflict-based search for optimal multi-agent pathfinding
Artificial Intelligence, 2015, 正式发表。

阅读重点：多智能体避碰搜索基线。重点读冲突树、顶点/边冲突和受约束单机搜索；为生成式方法建立时空搜索对照。